Devoir 3

Réalisé par

Boucher Alexandre (537354016)

Martin Tristan (537354429)

Dans le cadre du cours

Analyse numérique MAT-2910

Travail présenté à

Philippe-André Luneau

Département de mathématiques et de statistiques

Faculté des sciences et de génie

Université Laval

23 mars 2025

<u>Partie 2.1: Régression linéaire</u>

a)

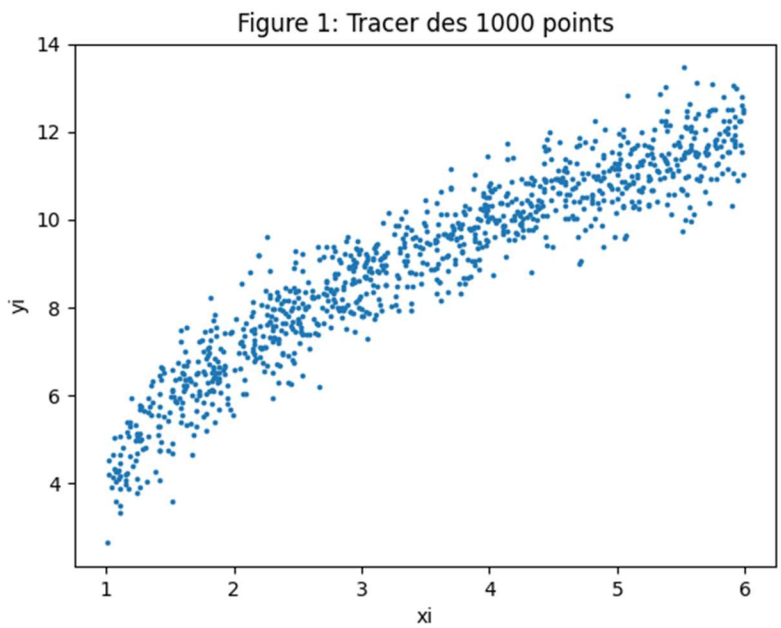

L'hypothèse sur la linéarité de f semble être confirmé. Sachant qu'on recherche f qui correspond à la relation pour les coordonnées en y des points en fonction de la coordonné en x ($f(x_i) = y_i \iff \beta_1 + \beta_2 x_i = y_i$), on remarque sur le tracer une tendance linéaire (avec une bonne corrélation) des y_i en fonction des x_i, donc que les coordonnées des points (x_i, y_i) semblent s'ordonnées linéairement.

b)

1. Résoudre $Q^T\vec{y}$

$$R\vec{\beta} \ = \ Q^T\vec{y}$$

Sachant que :

$$Q^T = \begin{bmatrix} q_{11} & q_{21} & \dots & q_{n1} \\ 1_{12} & q_{22} & \dots & q_{n2} \end{bmatrix}$$

$$\vec{y} = \begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{bmatrix}$$

Donc :

$$Q^T\vec{y} = \begin{bmatrix} q_{11}y_1 + q_{12}y_2 + \cdots + q_{1n}y_n \\ q_{21}y_1 + q_{22}y_2 + \cdots + q_{2n}y_n \end{bmatrix} = \begin{bmatrix} Q^T\vec{y}_1 \\ Q^T\vec{y}_2 \end{bmatrix}$$

Et :

$$R = \begin{bmatrix} r_{11} & r_{12} \\ 0 & r_{22} \end{bmatrix}$$

$$\vec{\beta} = \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix}$$

On peut résoudre ainsi en faisant une remontée triangulaire:

$$\begin{bmatrix} r_{11} & r_{12} \\ 0 & r_{22} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix} = \begin{bmatrix} Q^T\vec{y}_1 \\ Q^T\vec{y}_2 \end{bmatrix}$$

$L_2 * C_1 = Q^T\vec{y}_{21} = 0 * \beta_1 + r_{22} * \beta_2 = r_{22}\beta_2 = Q^T\vec{y}_2 \rightarrow \beta_2 = \frac{Q^T\vec{y}_2}{r_{22}}$ (1 multiplication)

$L_1 * C_1 = Q^T\vec{y}_{11} = r_{11} * \beta_1 + r_{12} * \beta_2 = r_{11}\beta_1 + r_{12}\beta_2 = Q^T\vec{y}_1 \rightarrow \beta_1 = \frac{Q^T\vec{y}_1 - r_{12}\beta_2}{r_{11}}$

(2 multiplications et 1 addition)

$Q^T\vec{y} = \begin{bmatrix} r_{11}\beta_1 + r_{12}\beta_2 \\ r_{22}\beta_2 \end{bmatrix}$ (1 multiplication + 2 multiplications + 1 addition = **4 opérations**)

2. Calcul de A^TA

$A = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \dots & \dots \\ 1 & x_n \end{bmatrix}$ et $A^T = \begin{bmatrix} 1 & 1 & \dots & 1 \\ x_1 & x_2 & \dots & x_n \end{bmatrix}$

Calcul des éléments de la matrice $A^T A$

$$(A^T A)_{11} = \sum_{i=1}^{n} (1 \times 1) = n \ (donc\ nombre\ d'opérations: n\ additions)$$

$$(A^T A)_{12} = \sum_{i=1}^{n} (1 \times x_i) = \sum_{i=1}^{n} x_i \ \ (donc\ nombre\ d'opérations: n\ additions)$$

$$(A^T A)_{21} = \sum_{i=1}^{n} (x_i \times 1) = \sum_{i=1}^{n} x_i \ \ (donc\ nombre\ opération: 0\ car\ copie\ de\ (A^T A)_{12})$$

$$(A^T A)_{22} = \sum_{i=1}^{n} (x_i \times x_i)$$
$$= \sum_{i=1}^{n} {x_i}^2 \ \ (donc\ nombre\ d'opérations: n\ additions + n\ multiplications)$$

La matrice résultante est une matrice carrée 2x2, donc le nombre total d'opération est de 4n, puisqu'il faut parcourir l'intégralité des n données pour trouver la valeur de chacun des 4 éléments. Ainsi, pour 1000 données, il y aura donc 4000 opérations. Une fois la matrice $A^T A$ calculée, sa décomposition LU ne nécessite qu'environ $\left(\frac{2}{3} \cdot m^3\right) = \left(\frac{2}{3} \cdot 2^3\right) \approx 5\ opérations$. Contrairement à $A^T A$, ce coût ne dépend pas de n, donc ça décomposition est négligeable comparativement a la décomposition de la matrice $A^T A$. Pour finir, lorsque n devient très grand, le coût $(4n)$ domine largement le terme constant de la matrice résultante 2x2 $\left(\frac{2}{3} \cdot m^3\right)$. Le coût asymptotique global de l'approche (A) est donc 4n. Il augmente linéairement avec le nombre de points données. La constante 4 n'affecte pas la classe de complexité, le coût reste $O(n)$.

c)

$\vec{\beta} = \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix} = \begin{bmatrix} 4.00933858 \\ 1.42326685 \end{bmatrix}$ (On obtient le même résultat avec les 2 méthodes)

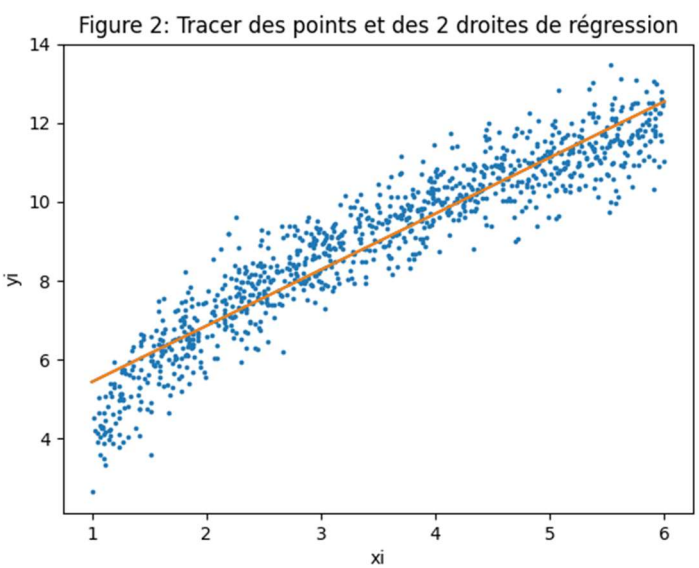

On remarque que les 2 droites de régression sont complètement superposées, ce qui permet de voir que les estimations sont équivalentes pour la tolérance donnée. C'est

exactement ce qu'il nous faut, car nos 2 droites nous ont permis de déterminer $\vec{\beta}$ pour avoir $\|F(\vec{\beta})\|$minimal et le fait qu'elle se superpose confirme que le $\vec{\beta}$ obtenu est le bon. De plus, alors que les droites ont une très bonne corrélation dans l'intervalle [1,5 : 6], on remarque cependant une moins bonne corrélation dans l'intervalle [1 : 1,5]. Il y a moins de points dans cet intervalle, donc la droite est moins contrainte.

$\|F(\vec{\beta})\|_A$ = $\|A\vec{\beta} - \vec{y}\|_A$= 23.89435600207109 pour la méthode A

$\|F(\vec{\beta})\|_B$ = $\|A\vec{\beta} - \vec{y}\|_B$= 23.894356002071085 pour la méthode B

Les résidus $F(\vec{\beta})_i$ représente la différence entre les valeurs réelles de y par rapport aux valeurs estimés par les droites de régression $(f(x_i) - y_i)$. Ici, les fonctions reglinA/B calcules la norme du vecteur résidu $\sqrt{F(\vec{\beta})^2{}_1 + F(\vec{\beta})^2{}_2 + \cdots + F(\vec{\beta})^2{}_n}$ où $F(\vec{\beta})_n = [1 \quad x_n]\vec{\beta} - y_n$ qui est le résidu résultant pour chaque droite. Cette norme indique la longueur du vecteur des erreurs, soit la différence entre la réalité et l'estimé du modèle au complet, entre les valeurs de y_i et celle de $f(x_i)$.

<u>Partie 2.2 : Régression non linéaire</u>

d)

1) Système d'équation dans le cas générale

On cherche à trouver une racine de $\vec{f}(\vec{x}) = \vec{0}$ afin de résoudre un système non linéaire.

Sachant que :

$f(x_i) = \beta_1 + \beta_2\sqrt{x_i - \beta_3}$ (Estimation de y_i)

Donc :

$F(\vec{\beta})_i = f(x_i) - y_i = \beta_1 + \beta_2\sqrt{x_i - \beta_3} - y_i$

$\vec{F}(\vec{\beta}) = Matrice\ n * 1\ des\ F(\vec{\beta})_i$ (Ensemble des résidus pour chaque coordonné (x_i, y_i))

(n équations pour 3 inconnus)

$$\vec{F}(\vec{\beta}) = \begin{bmatrix} f(x_1, \vec{\beta}) - y_1 \\ f(x_2, \vec{\beta}) - y_2 \\ \dots \\ f(x_n, \vec{\beta}) - y_n \end{bmatrix} = \begin{bmatrix} \beta_1 + \beta_2\sqrt{x_1 - \beta_3} + y_1 \\ \beta_1 + \beta_2\sqrt{x_2 - \beta_3} + y_2 \\ \dots \\ \beta_1 + \beta_2\sqrt{x_n - \beta_3} + y_n \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \dots \\ 0 \end{bmatrix}$$

$\vec{x}$ = Matrice n * 1 des x_i

$\vec{y}$ = Matrice n * 1 des y_i

$\vec{F}(\vec{\beta}) = \beta_1 + \beta_2\sqrt{\vec{x} - \beta_3} - \vec{y} = 0$ (car on cherche le résidu le plus petites possible, donc 0)

Et cela correspond à trouver une racine pour $\vec{F}(\vec{\beta})$ (le $\vec{\beta}$ où $\vec{F}(\vec{\beta})$ = 0) donc, avec la méthode de Newton :

$$Estimation\ de\ \vec{\beta}\ (\overrightarrow{\beta_{n+1}}) = g_N = \vec{\beta}_n - \frac{\vec{F}(\overrightarrow{\beta_n})}{\vec{F}'(\vec{\beta}_n)} = \vec{\beta}_n - \frac{\vec{F}(\overrightarrow{\beta_n})}{J_F(\overrightarrow{\beta_n})}$$

$$\delta\vec{\beta} = \vec{\beta}_{n+1} - \vec{\beta}_n = -\frac{\vec{F}(\overrightarrow{\beta_n})}{J_F(\overrightarrow{\beta_n})}$$

Ainsi :

$$J_F(\vec{\beta}) = \begin{bmatrix} \frac{\partial F_1(\beta_1,\beta_2,\beta_3)}{\partial \beta_1} & \frac{\partial F_1(\beta_1,\beta_2,\beta_3)}{\partial \beta_2} & \frac{\partial F_1(\beta_1,\beta_2,\beta_3)}{\partial \beta_3} \\ \frac{\partial F_2(\beta_1,\beta_2,\beta_3)}{\partial \beta_1} & \frac{\partial F_2(\beta_1,\beta_2,\beta_3)}{\partial \beta_2} & \frac{\partial F_2(\beta_1,\beta_2,\beta_3)}{\partial \beta_3} \\ \dots & \dots & \dots \\ \frac{\partial F_n(\beta_1,\beta_2,\beta_3)}{\partial \beta_1} & \frac{\partial F_n(\beta_1,\beta_2,\beta_3)}{\partial \beta_2} & \frac{\partial F_n(\beta_1,\beta_2,\beta_3)}{\partial \beta_3} \end{bmatrix} = \begin{bmatrix} 1 & \sqrt{x_1 - \beta_3} & -\frac{\beta_2}{2\sqrt{x_1-\beta_3}} \\ 1 & \sqrt{x_2 - \beta_3} & -\frac{\beta_2}{2\sqrt{x_2-\beta_3}} \\ \dots & \dots & \dots \\ 1 & \sqrt{x_n - \beta_3} & -\frac{\beta_2}{2\sqrt{x_n-\beta_3}} \end{bmatrix}$$

$$\vec{F}(\vec{\beta}) = \begin{bmatrix} f(x_1, \vec{\beta}) - y_1 \\ f(x_2, \vec{\beta}) - y_2 \\ \dots \\ f(x_n, \vec{\beta}) - y_n \end{bmatrix}$$

Avec n = 1000, on ne peut pas résoudre le système par la méthode de Newton car :

$\frac{\vec{F}(\vec{\beta})}{J_F(\vec{\beta})} = \vec{F}(\vec{\beta})J_F^{-1}(\vec{\beta})$= multiplication de matrice incompatible (nx1 et nx3), le calcul ne pourra donc pas être effectué. De plus, dans la méthode de Newton de base, le jacobien doit être carré. Pour résoudre ce type de système, il faudrait utiliser l'approche par moindres carrés afin de transformer ce problème dans un système d'équation carrée.

f)

$$\beta_1 = 2{,}85619017$$

$$\beta_2 = 4{,}06994648$$

$$\beta_3 = 0{,}97482303$$

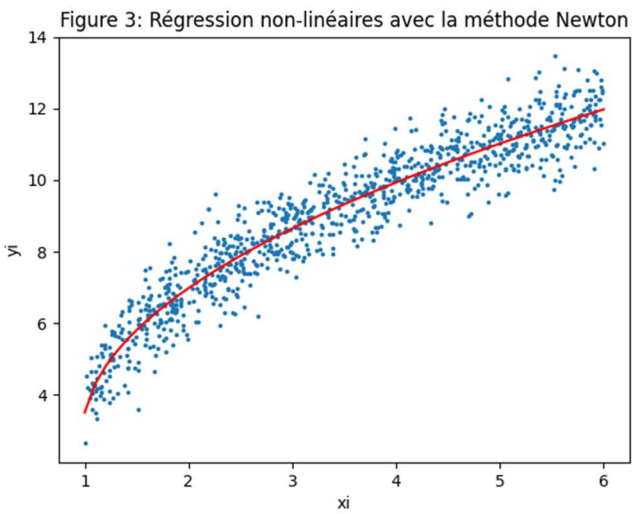

e)

Il faut décomposer la jacobienne rectangulaire (1000x3), car c'est un système surdéterminé. On le décompose en matrice Q (1000x3) et R(3x3), soit $J = QR$. On se retrouve avec $QR\delta\beta = -F$. On multiplie chaque côté par la transposée de Q, soit $R\delta\beta = -Q^T F$. Ensuite, il faut résoudre le système, en sachant que la matrice R est triangulaire supérieur. Ainsi, on passe d'un problème avec une matrice rectangulaire de (1000x3) à une matrice (3x3).

g)

La dernière valeur de $\left\|F(\beta^{(k)})\right\| = 20{,}45717142086425$. C'est la norme du résidu final. Elle ne tend pas vers 0, car c'est la somme de tous les écarts entre la courbe de régression sur l'intervalle [1, 6] et le nuage de point. Ainsi, si c'était 0, la somme des résidus serait de 0 et tous les points du nuage seraient exactement positionnés sur la courbe de régression.

Itération 3 : $\left\|\delta\beta^{(4)}\right\|$ = 9.449850398702157e-05,

Itération 4 : $\left\|\delta\beta^{(5)}\right\|$= 9.36695203313192e-06

Itération 5 : $\left\|\delta\beta^{(6)}\right\|$= 9.315190257756965e-07

Itération 6 : $\left\|\delta\beta^{(7)}\right\|$= 9.267080482787699e-08

$$\frac{\left\|\delta\beta^{(5)}\right\|}{\|\delta\beta^{(4)}\|} \approx 0{,}1$$

$$\frac{\left\|\delta\beta^{(5)}\right\|}{\|\delta\beta^{(4)}\|} \approx 0{,}1$$

$$\frac{\left\|\delta\beta^{(5)}\right\|}{\|\delta\beta^{(4)}\|} \approx 0{,}1$$

Donc la méthode converge vers l'ordre $p = 1$, car le rapport entre deux erreurs successives est constant : $\frac{\|\delta\beta^{(k+1)}\|}{\|\delta\beta^{(k)}\|} \approx 0{,}1$. Puisque ça tend vers une constante non nulle, c'est une convergence linéaire. Aussi, lorsque le résidu est non nul, la convergence s'approche d'une convergence linéaire.

Partie 2.3 : Régression linéaire dans l'espace des fréquences

h)

$$A\vec{\beta} = \vec{y}$$

$$f(x_j) = y_j \Leftrightarrow \sum_{i=1}^{k} \beta_i \cos\left((i-1)x_j + \sum_{i=k+1}^{2k-1} \beta_i \sin\left((i-k)x_j = y_j\right.\right.$$

$$A = \begin{bmatrix} 1 & \cos(x_1) & \dots & \cos((k-1)x_1) & \sin(x_1) & \sin(2x_1) & \dots & \sin((k-1)x_1) \\ 1 & \cos(x_2) & \dots & \cos((k-1)x_2) & \sin(x_2) & \sin(2x_2) & \dots & \sin((k-1)x_2) \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 1 & \cos(x_n) & \dots & \cos((k-1)x_n) & \sin(x_n) & \sin(2x_n) & \dots & \sin((k-1)x_n) \end{bmatrix}$$

Dimension : n lignes par 2k-1 colonnes

j)

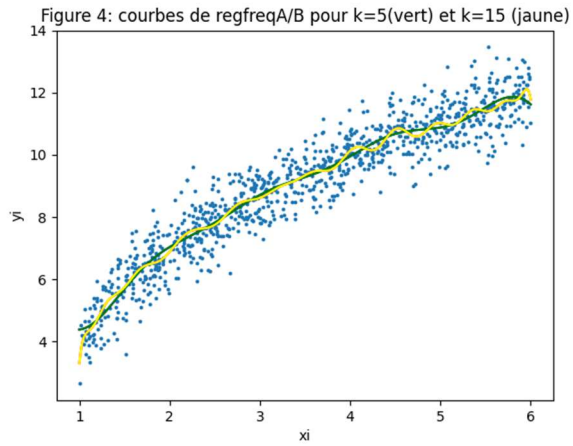

$$\left\|F(\vec{\beta})\right\|_{A_{k=5}} = \left\|A\vec{\beta} - \vec{y}\right\|_{A_{k=5}} = 20.59739684958329$$

$$\left\|F(\vec{\beta})\right\|_{B_{k=5}} = \left\|A\vec{\beta} - \vec{y}\right\|_{B_{k=5}} = 20.59739684958329$$

$$\left\|F(\vec{\beta})\right\|_{A_{k=15}} = \left\|A\vec{\beta} - \vec{y}\right\|_{A_{k=15}} = 20.179670293015192$$

$$\left\|F(\vec{\beta})\right\|_{B_{k=15}} = \left\|A\vec{\beta} - \vec{y}\right\|_{B_{k=15}} = 20.17967029301517$$

Pour rappel, la norme du vecteur résidu donne la précision de l'estimer par rapport à la réalité sur l'ensemble des points, soit donc la longueur du vecteur d'erreur. On remarque que ces normes sont les plus faible des méthodes de régression, et donc que cette méthode de régression est la plus précise. De plus, ceci est confirmé par l'observation du graphique où on voit clairement les courbes être attiré par les « centre de masse » de points, ce qui fait qu'elle zigzag (à cause de ses termes trigonométriques) et donc que la méthode aura plus tendance à se rapprocher des vraies valeurs de y_i. Autrement, on remarque que les méthodes A et B sont encore une fois très similaire et que plus k est grand (et donc plus que nous rajoutons des coefficients), plus la méthode est précise.

k)

Temps moyen pour regfreqA avec k = 5 : 0.0009306659698486328 s

Temps moyen pour regfreqA avec k = 15 : 0.001645537853240967 s

Temps moyen pour regfreqB avec k = 5 : 0.0009089767932891846 s

Temps moyen pour regfreqB avec k = 15 : 0.0033575122356414794 s

Conditionnement de $A^T A$ pour k = 5 : 68.06104159645194

Conditionnement de $A^T A$ pour k = 15 : 18780093.09994202

Conditionnement de R pour k = 5 : 8.2499116114327

Conditionnement de R pour k = 15 : 4333.600476911695

Avec ces dernières mesures, nous pouvons remarquer que bien que le résidu diminue alors que k augmente (le nombre de coefficients utilisé augmente), utiliser un k plus grand amène aussi des désavantages qui rend cette façon moins valide et donc que faire tendre k vers l'infini ne serait pas une solution viable. D'abord, le temps de résolution semble augmenter de façon exponentiel (environ 0,005s de plus pour 1000 appels de la fonction) alors que la différence de k est seulement de 10, ce qui indique que l'efficacité n'augmente pas de façon linéaire. Ensuite, sur le plan de la fiabilité, indiqué par le conditionnement, où par les valeurs obtenues, on remarque que les résidus calculés avec k = 15 ne sont pas significatifs par rapport aux erreurs sur $A^T A$ et R et donc que le résidu n'a aucune valeur par sa propriété à grandement varier à cause du fort conditionnement pour les k plus grand.

Autrement, pour comparer les méthodes A et B, alors que la différence entre les 2 est négligeable pour les k petits, la méthode A est légèrement plus efficace que la méthode B pour les k plus grand, car elle a un temps d'exécution significativement plus courts. Ensuite, pour la fiabilité, les deux méthodes sont assez fiables à bas k (avec une différence entre les 2 négligeable selon l'usage) mais la méthode A est très peu fiable à haut k alors que la méthode B reste modérément fiable (selon l'usage), où les erreurs calculées seront un peu moins amplifier. Au final, les 2 méthodes sont équivalente à bas k, mais pour des k plus hauts, il faut favoriser la méthode B qui malgré qu'elle soit légèrement plus lente, elle est énormément plus fiable.

l)

Pour méthode A :

$$\frac{||\Delta\beta||}{||\beta||} \leq cond(A^T A)\frac{||\Delta y||}{||y||} = cond(A^T A) * 10^{-15}$$

Avec k = 5 :

$\frac{||\Delta\beta||}{||\beta||} \leq 68.06104159645194 * 10^{-15} = 6{,}8 \ldots * 10^{-14}$ (Négligeable ok)

Avec k = 15 :

$\frac{||\Delta\beta||}{||\beta||} \leq 18780093.09994202 * 10^{-15} = 1{,}8 \ldots * 10^{-8}$ (Relativement petite)

Pour méthode B :

$$\frac{||\Delta\beta||}{||\beta||} \leq cond(R)\frac{||\Delta y||}{||y||} = cond(R) * 10^{-15}$$

Avec k = 5 :

$\frac{||\Delta\beta||}{||\beta||} \leq 8.2499116114327 * 10^{-15} = 8{,}2 \ldots * 10^{-15}$ (Négligeable ok)

Avec k = 15 :

$\frac{||\Delta\beta||}{||\beta||} \leq 4333.600476911695 * 10^{-1} = 1{,}4 \ldots * 10^{-12}$ (Négligeable ok)

Avec les bornes supérieures de l'erreur relative sur β qui sont toutes négligeable peu importe k, les mesures sur le résidu sont assez précises et n'amplifie pas l'erreur. Finalement, on remarque ici que la méthode B est meilleure que la méthode A, surtout pour les cas moins bien conditionner. La méthode B est numériquement plus stable car le conditionnement de R est la racine carrée du conditionnement de $A^T A$, ce qui augmenter beaucoup moins les erreurs machines.